BÁO CÁO THỰC NGHIỆM LAB03 – CUSTOMER SEGMENTATION

Báo cáo tổng hợp quá trình khám phá dữ liệu, tiền xử lý, huấn luyện và đánh giá mô hình K-means.

1. Thông tin lần chạy

Thông tin	Giá trị
Run_ID	20261111_012322_8b668d
Trạng thái	SUCCESS
Bắt đầu	2026-11-11T01:23:22+07:00
Kết thúc	2026-11-11T01:23:26+07:00
Tổng thời gian	Không có dữ liệu
Progress file	progress_results\progress_20261111_012322_8b668d.json
Log file	logs\pipeline_20261111_012322_8b668d.log

2. Tổng quan Pipeline

Pipeline Lab03 được tổ chức theo bốn giai đoạn chính:

```
D■ li■u ■■u vào
      |
      v
1. EDA – Khám phá d■ li■u
      |
      v
2. PREPROCESSING – Làm s■ch và chu■n hóa
      |
      v
3. TRAINING – Hu■n luy■n K-means
      |
      v
4. EVALUATION – ■ánh giá k■t qu■ phân c■m
      |
      v
Visualization -> Tracking -> Report
```

Mỗi giai đoạn nhận đầu vào từ giai đoạn trước, thực hiện nhiệm vụ riêng và tạo ra đầu ra phục vụ bước tiếp theo.

3. Tiến trình thực hiện và Tracking

Giai đoạn	Trạng thái	Thời gian bắt đầu	Thời gian kết thúc	Thời gian chạy	Thông tin
EDA	START				
EDA	SUCCESS				
PREPROCESSING	START				
PREPROCESSING	SUCCESS				
TRAINING	START				
TRAINING	SUCCESS				
EVALUATION	START				
EVALUATION	SUCCESS				
VISUALIZATION	START				
VISUALIZATION	SUCCESS				
PIPELINE	SUCCESS				

File progress_results/progress_<Run_ID>.json lưu trạng thái và thông tin tiến trình của lần chạy. File log lưu các sự kiện bắt đầu, hoàn thành hoặc lỗi trong quá trình thực thi.

4. Giải thích các giai đoạn trong Pipeline

4.1. EDA – Exploratory Data Analysis

Mục đích: Khảo sát cấu trúc dữ liệu, kiểu dữ liệu, phân phối các thuộc tính và mối quan hệ giữa các biến.

Input: data/raw/customer_segmentation.csv.

Các công việc chính:

• Đọc và kiểm tra dữ liệu đầu vào.

• Kiểm tra số lượng bản ghi, thuộc tính và kiểu dữ liệu.

• Khảo sát dữ liệu thiếu, dữ liệu trùng lặp và ngoại lệ.

• Quan sát phân phối Age, Annual Income và Spending Score.

• Phân tích mối quan hệ giữa các đặc trưng.

Output: Các thống kê mô tả, bảng phân tích và biểu đồ EDA được lưu trong thư mục hình ảnh của lần chạy.

4.2. Preprocessing – Tiền xử lý dữ liệu

Mục đích: Chuẩn bị dữ liệu hợp lệ và đưa các đặc trưng về cùng thang đo trước khi huấn luyện K-means.

Input: Dữ liệu gốc từ data/raw/customer_segmentation.csv.

Các công việc chính:

• Loại bỏ các bản ghi trùng lặp.

• Chuyển các thuộc tính số về kiểu dữ liệu phù hợp.

• Loại bỏ bản ghi thiếu hoặc chứa giá trị không hợp lệ.

• Chọn ba đặc trưng: Age, Annual Income, Spending Score.

• Không sử dụng Customer ID làm đặc trưng phân cụm.

• Giữ Gender để hỗ trợ phân tích hồ sơ cụm nếu cần.

Chuẩn hóa Z-score:

\[z = \frac{x-\mu}{\sigma}\]

Trong đó:

• x: giá trị ban đầu.

• μ: giá trị trung bình của đặc trưng.

• σ: độ lệch chuẩn của đặc trưng.

• z: giá trị sau chuẩn hóa.

Output:

• data/processed/customers_clean.csv.

• data/processed/X_scaled.csv.

• data/processed/scaler.json.

Kết quả tiền xử lý

• Số dòng sau làm sạch: 15,079.

• Số dòng dữ liệu sau chuẩn hóa: 15,079.

• Số đặc trưng được sử dụng: 3.

• Các đặc trưng: Age, Annual Income, Spending Score.

Một số dòng dữ liệu sau làm sạch:

Customer ID	Age	Gender	Annual Income	Spending Score
d410ea53-6661-42a9-ad3a-f554b05fd2a7	30	Male	151479	89
1770b26f-493f-46b6-837f-4237fb5a314e	58	Female	185088	95
e81aa8eb-1767-4b77-87ce-1620dc732c5e	62	Female	70912	76
9795712a-ad19-47bf-8886-4f997d6046e3	23	Male	55460	57
64139426-2226-4cd6-bf09-91bce4b4db5e	24	Male	153752	76

Bảng hiển thị 5/15079 dòng đầu tiên.

Một số dòng dữ liệu sau chuẩn hóa:

Age	Annual Income	Spending Score
-1.1455	0.7988	1.3371
0.1803	1.4421	1.5459
0.3697	-0.7432	0.8845
-1.4770	-1.0390	0.2231

Age	Annual Income	Spending Score
-1.4296	0.8423	0.8845

Bảng hiển thị 5/15079 dòng đầu tiên.

4.3. Training – Huấn luyện mô hình K-means

Mục đích: Tìm cách chia tập khách hàng thành các cụm sao cho các điểm dữ liệu trong cùng cụm gần nhau theo khoảng cách trong không gian đặc trưng.

Input: X_scaled.csv và cấu hình mô hình.

Quy trình:

• Khởi tạo các tâm cụm.

• Gán mỗi khách hàng vào tâm cụm gần nhất.

• Cập nhật tâm cụm bằng trung bình các điểm thuộc cụm.

• Lặp lại quá trình gán cụm và cập nhật tâm cho đến khi hội tụ hoặc đạt giới hạn số vòng lặp.

• Thử nghiệm các giá trị K và so sánh chỉ số đánh giá.

Các chỉ số sử dụng:

• Inertia: Tổng bình phương khoảng cách từ các điểm dữ liệu đến tâm cụm tương ứng. Inertia càng thấp thì các điểm trong cụm càng gần tâm cụm, nhưng chỉ số này thường giảm khi tăng K.

• Silhouette Score: Đánh giá mức độ gắn kết trong cụm và mức độ tách biệt với cụm gần nhất. Giá trị nằm trong khoảng [-1, 1], càng cao thường thể hiện cấu trúc cụm càng rõ.

Output: Mô hình K-means tốt nhất và bảng kết quả thử nghiệm K.

Bảng kết quả thử nghiệm K

K	Inertia	Silhouette Score (sample)	Iterations	Time (seconds)
2	33,927.6926	0.2401	22	0.0561
3	26,997.0444	0.2320	32	0.1396
4	21,502.2601	0.2550	22	0.1107
5	18,088.5254	0.2672	60	0.1452
6	14,905.6510	0.2859	60	0.1717
7	13,170.8885	0.2721	25	0.0885
8	11,315.0007	0.2724	37	0.0978

Cấu hình có Silhouette Score cao nhất

• K: 6

• Inertia: 14,905.6510

• Silhouette Score (sample): 0.2859

• Iterations: 60

• Time (seconds): 0.1717

4.4. Evaluation – Đánh giá kết quả phân cụm

Mục đích: Phân tích kết quả phân cụm sau khi mô hình K-means đã gán nhãn cho từng khách hàng.

Input: Mô hình K-means tốt nhất, dữ liệu đã làm sạch và dữ liệu chuẩn hóa.

Các công việc chính:

• Gán nhãn cụm cho từng khách hàng.

• Tính số lượng khách hàng trong mỗi cụm.

• Tính tỷ lệ khách hàng của từng cụm.

• Tính các giá trị trung bình để xây dựng hồ sơ cụm.

• Trực quan hóa sự phân bố giữa các cụm.

Output:

• customer_clusters.csv.

• cluster_profile.csv.

• Các biểu đồ đánh giá phân cụm.

5. Kết quả phân cụm

5.1. Số lượng khách hàng trong từng cụm

Cluster	Customer_Count	Percentage
0	2,629	17.4300
1	2,486	16.4900
2	2,461	16.3200
3	2,352	15.6000
4	2,628	17.4300
5	2,523	16.7300

5.2. Hồ sơ và đặc điểm các cụm

Cluster	Age_count	Age_mean	Age_median	Annual Income_count	Annual Income_mean	Annual Income_median	Spending Score_count	Spending Score_mean	Spending Score_median	Gender_%_Female	Gender_%_Male
0	2,629	34.1236	33	2,629	59,143.5455	56,232	2,629	41.7356	42	48.8800	51.1200
1	2,486	35.8415	35	2,486	141,740.7977	143,512.5000	2,486	78.3833	79	49.4400	50.5600
2	2,461	72.6067	73	2,461	78,488.1081	78,191	2,461	22.6806	22	49.7800	50.2200
3	2,352	40.6705	41	2,352	155,059.1828	157,199	2,352	22.8240	22	51.4000	48.6000
4	2,628	74.5909	75	2,628	160,891.4060	162,428	2,628	57.6781	58	48.3300	51.6700
5	2,523	66.5775	67	2,523	65,904.0210	64,788	2,523	78.1649	79	50.1800	49.8200

Nhận xét theo hồ sơ cụm

• Cụm Không xác định: Age_count: 2,629; Age_mean: 34.1236; Age_median: 33; Annual Income_count: 2,629; Annual Income_mean: 59,143.5455; Annual Income_median: 56,232; Spending Score_count: 2,629; Spending Score_mean: 41.7356; Spending Score_median: 42; Gender_%_Female: 48.8800; Gender_%_Male: 51.1200

• Cụm 1.0: Age_count: 2,486; Age_mean: 35.8415; Age_median: 35; Annual Income_count: 2,486; Annual Income_mean: 141,740.7977; Annual Income_median: 143,512.5000; Spending Score_count: 2,486; Spending Score_mean: 78.3833; Spending Score_median: 79; Gender_%_Female: 49.4400; Gender_%_Male: 50.5600

• Cụm 2.0: Age_count: 2,461; Age_mean: 72.6067; Age_median: 73; Annual Income_count: 2,461; Annual Income_mean: 78,488.1081; Annual Income_median: 78,191; Spending Score_count: 2,461; Spending Score_mean: 22.6806; Spending Score_median: 22; Gender_%_Female: 49.7800; Gender_%_Male: 50.2200

• Cụm 3.0: Age_count: 2,352; Age_mean: 40.6705; Age_median: 41; Annual Income_count: 2,352; Annual Income_mean: 155,059.1828; Annual Income_median: 157,199; Spending Score_count: 2,352; Spending Score_mean: 22.8240; Spending Score_median: 22; Gender_%_Female: 51.4000; Gender_%_Male: 48.6000

• Cụm 4.0: Age_count: 2,628; Age_mean: 74.5909; Age_median: 75; Annual Income_count: 2,628; Annual Income_mean: 160,891.4060; Annual Income_median: 162,428; Spending Score_count: 2,628; Spending Score_mean: 57.6781; Spending Score_median: 58; Gender_%_Female: 48.3300; Gender_%_Male: 51.6700

• Cụm 5.0: Age_count: 2,523; Age_mean: 66.5775; Age_median: 67; Annual Income_count: 2,523; Annual Income_mean: 65,904.0210; Annual Income_median: 64,788; Spending Score_count: 2,523; Spending Score_mean: 78.1649; Spending Score_median: 79; Gender_%_Female: 50.1800; Gender_%_Male: 49.8200

5.3. Dữ liệu khách hàng sau khi gán cụm

• Tổng số bản ghi: 15,079.

• Số thuộc tính: 6.

Một số bản ghi:

Customer ID	Age	Gender	Annual Income	Spending Score	Cluster
d410ea53-6661-42a9-ad3a-f554b05fd2a7	30	Male	151479	89	1
1770b26f-493f-46b6-837f-4237fb5a314e	58	Female	185088	95	1
e81aa8eb-1767-4b77-87ce-1620dc732c5e	62	Female	70912	76	5
9795712a-ad19-47bf-8886-4f997d6046e3	23	Male	55460	57	0
64139426-2226-4cd6-bf09-91bce4b4db5e	24	Male	153752	76	1

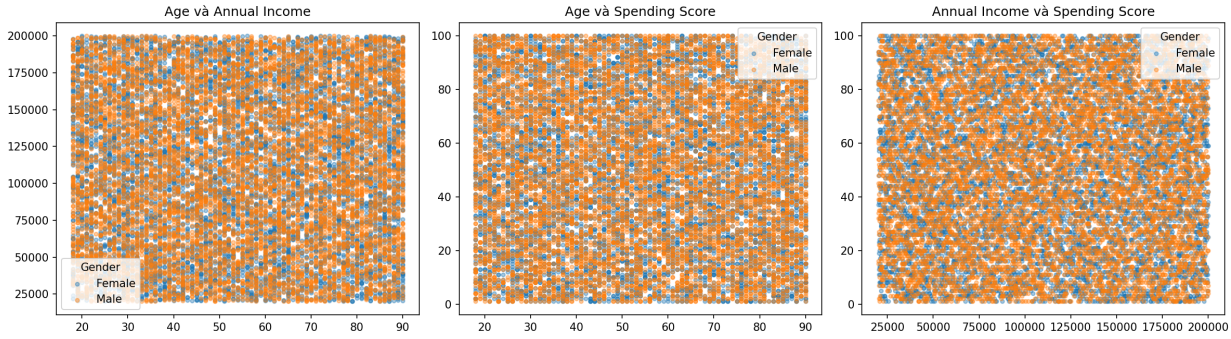
Bảng hiển thị 5/15079 dòng đầu tiên.

6. Biểu đồ và trực quan hóa

Các biểu đồ được nhóm theo từng giai đoạn của Pipeline. Mỗi hình ảnh thể hiện một khía cạnh của dữ liệu hoặc kết quả phân cụm.

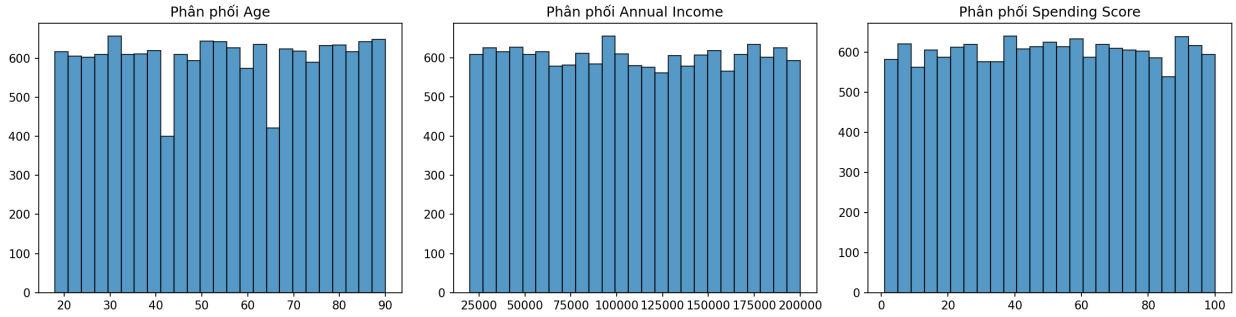
6.1. EDA – Khám phá dữ liệu

Eda Scatterplots



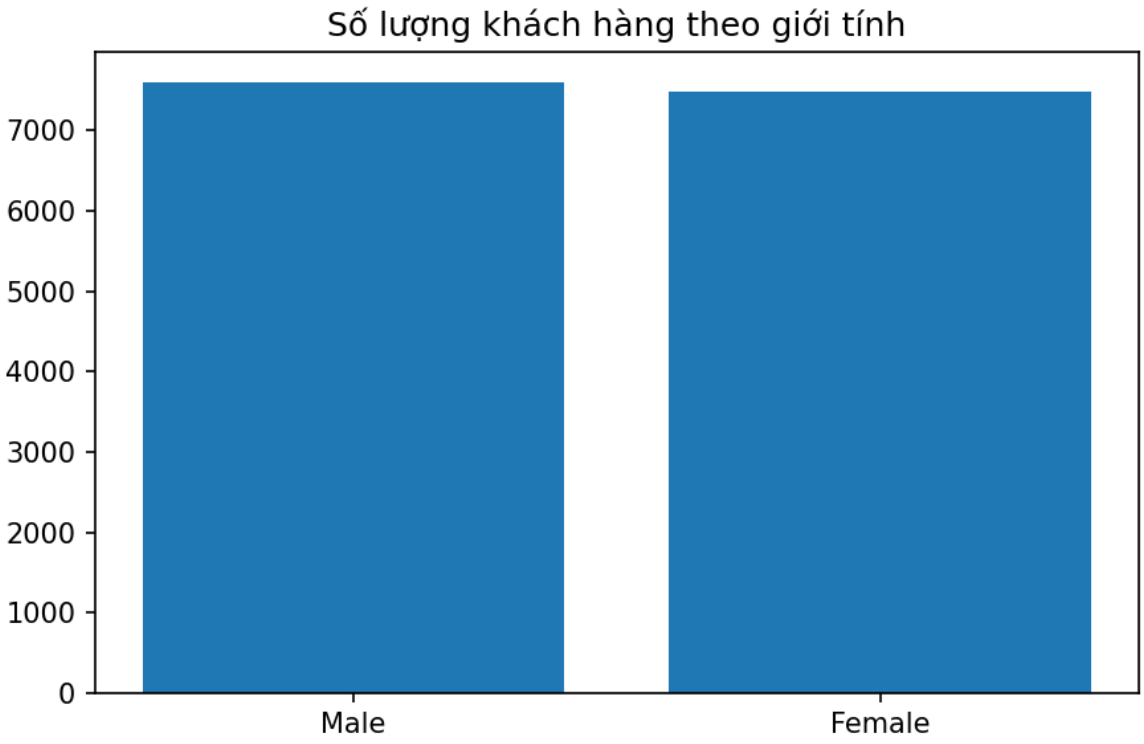
Biểu đồ phân tán thể hiện mối quan hệ giữa các đặc trưng và hỗ trợ quan sát cấu trúc dữ liệu.

Feature Distributions



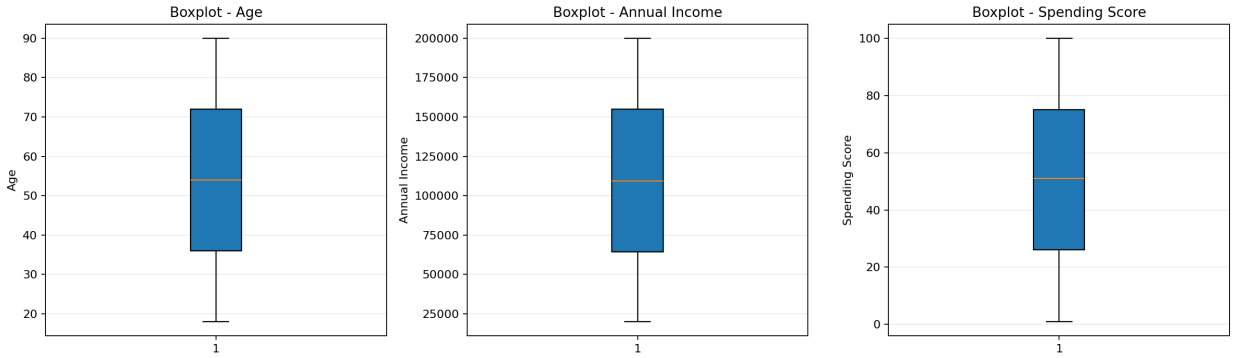
Biểu đồ phân phối giúp quan sát hình dạng phân phối của từng đặc trưng.

Gender Distribution



Biểu đồ thể hiện phân bố giới tính trong tập dữ liệu.

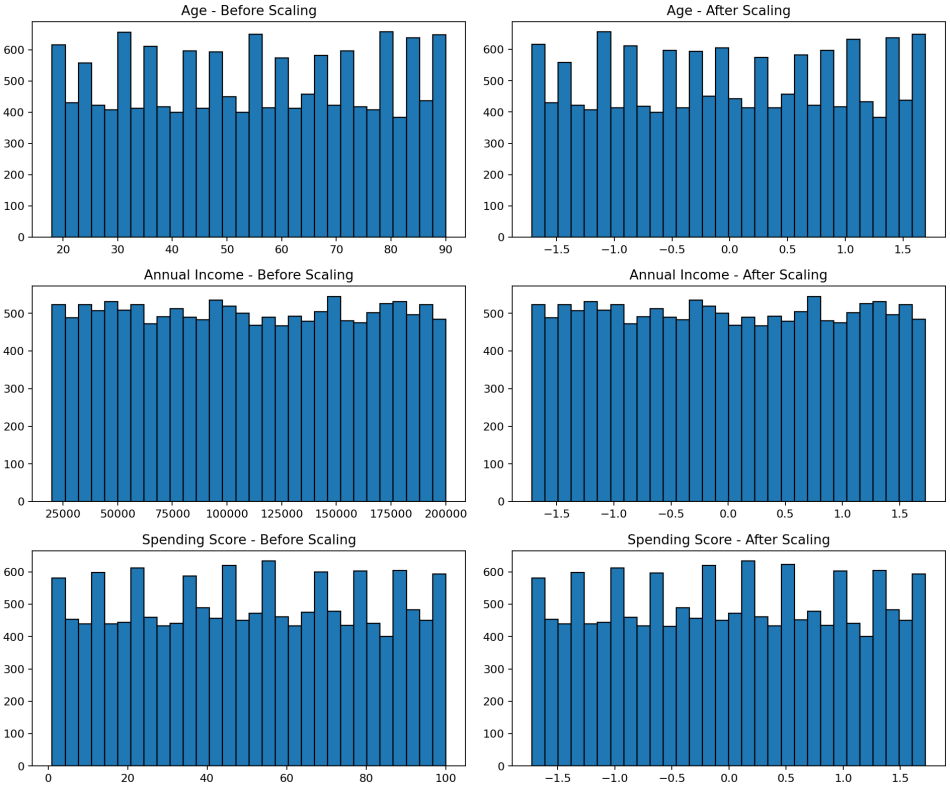
Outlier Boxplots



Biểu đồ boxplot hỗ trợ quan sát phân phối dữ liệu và phát hiện các giá trị có khả năng là ngoại lệ.

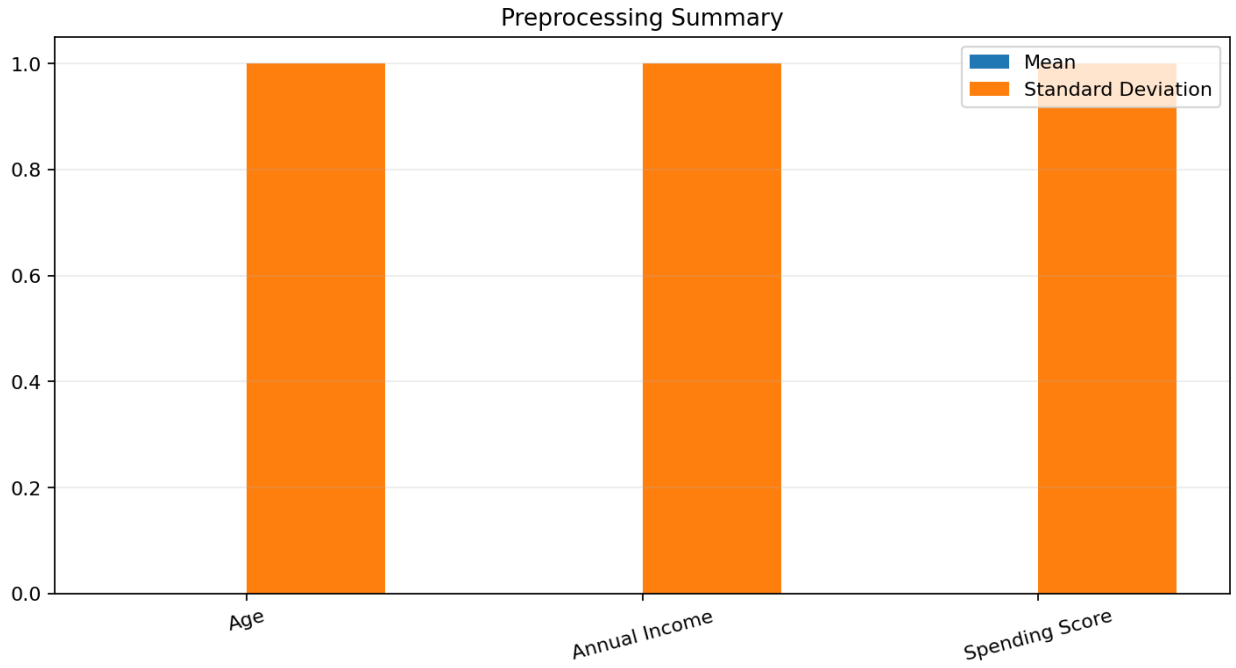
6.2. Preprocessing – Tiền xử lý dữ liệu

Before After Scaling



So sánh phân phối đặc trưng trước và sau chuẩn hóa Z-score.

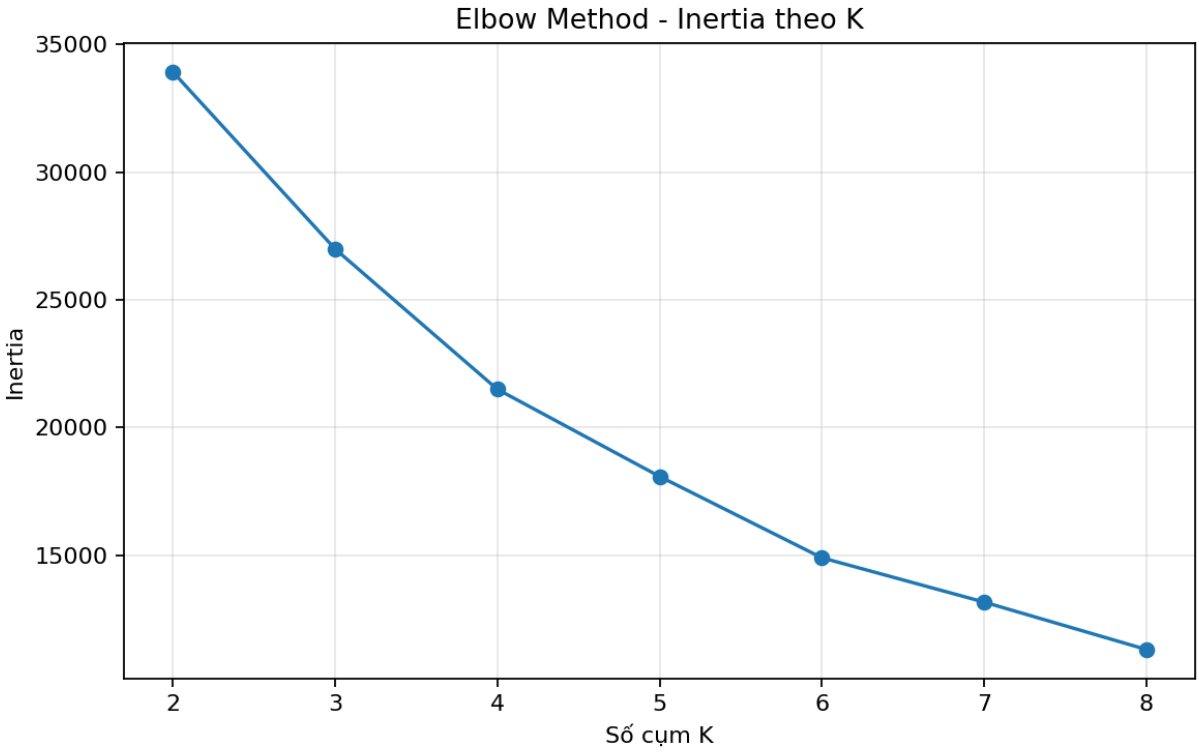
Preprocessing Summary



Tổng hợp số lượng bản ghi qua các bước làm sạch dữ liệu.

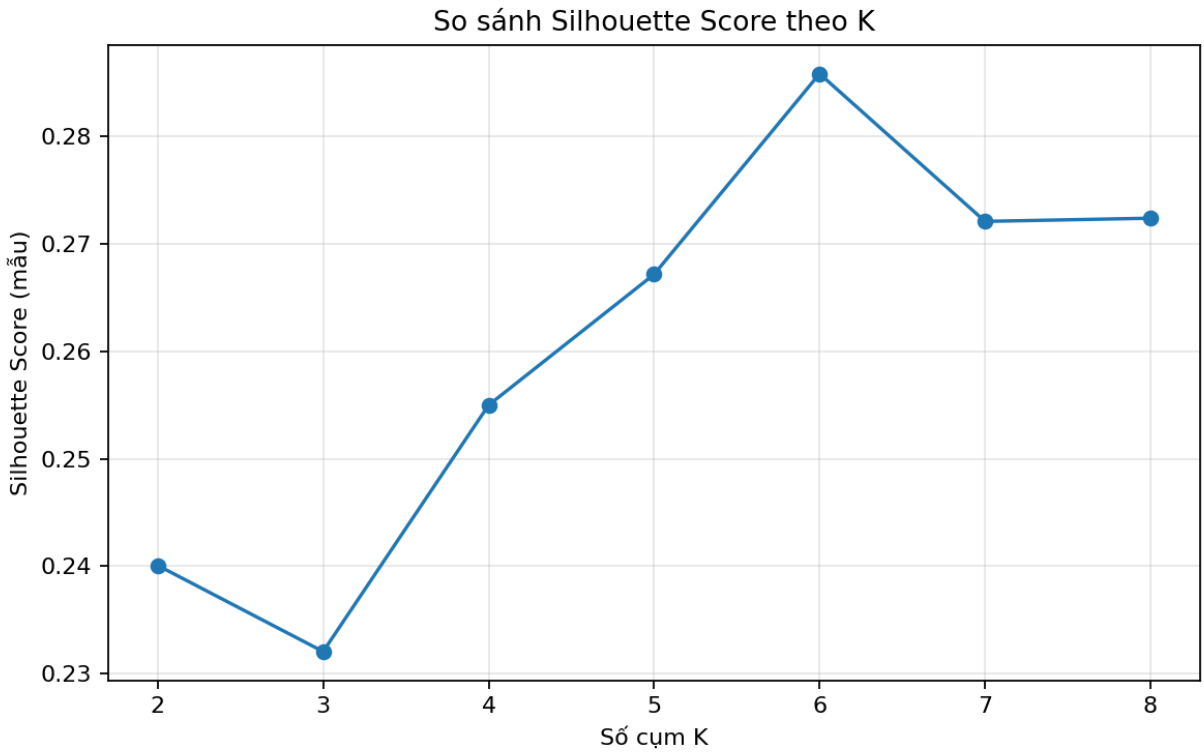
6.3. Training – Huấn luyện K-means

Elbow Method



Phương pháp Elbow thể hiện sự thay đổi Inertia theo số cụm K. Điểm khuỷu tay có thể hỗ trợ lựa chọn K.

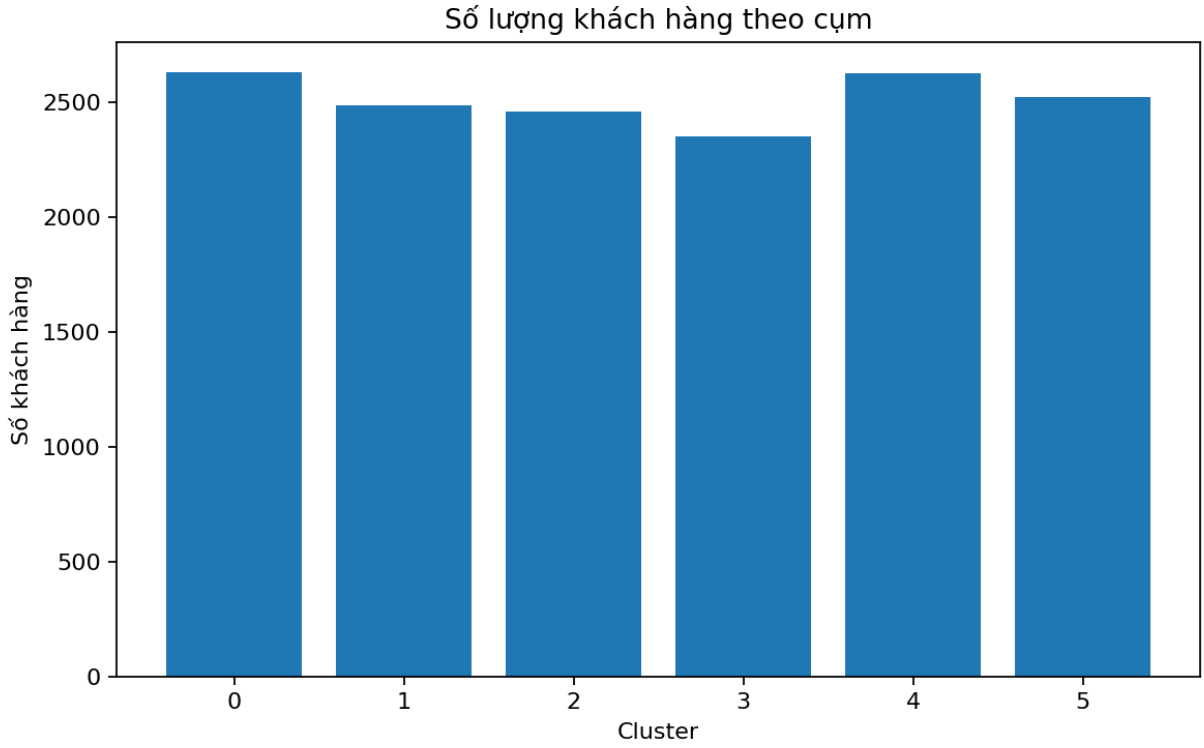
Silhouette By K



Silhouette Score dùng để đánh giá mức độ gắn kết trong cụm và tách biệt giữa các cụm.

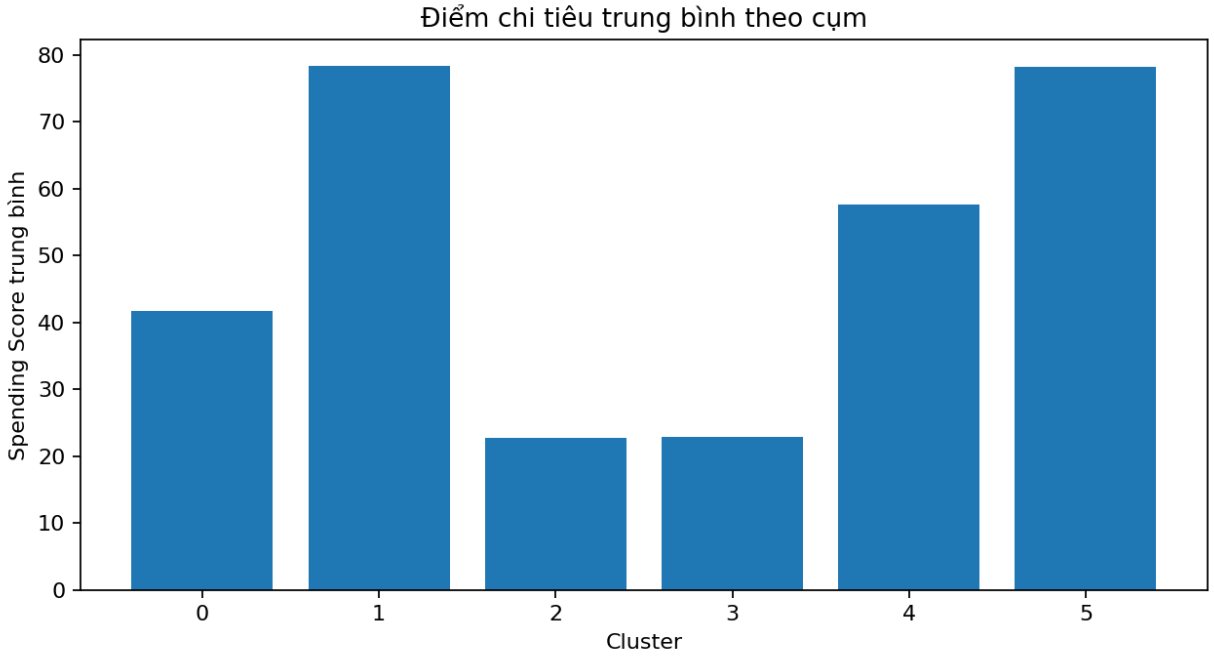
6.4. Evaluation – Đánh giá phân cụm

Cluster Sizes



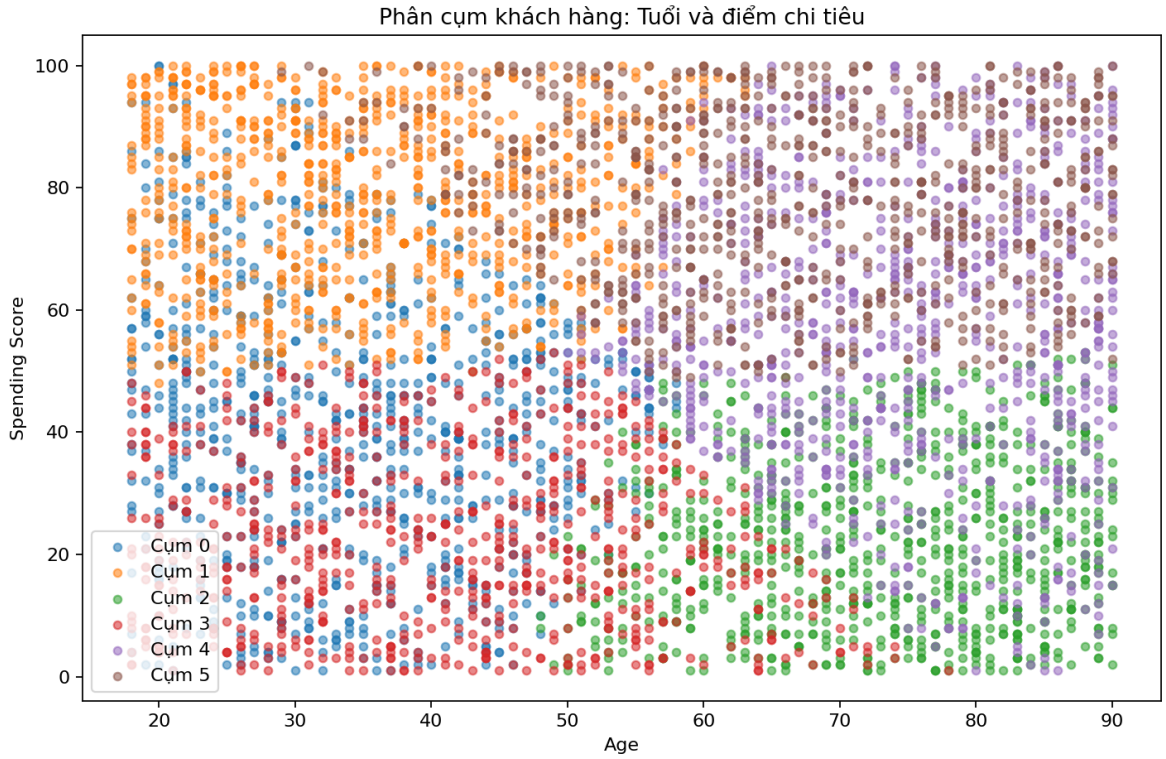
Biểu đồ thể hiện số lượng khách hàng thuộc từng cụm.

Cluster Spending Means



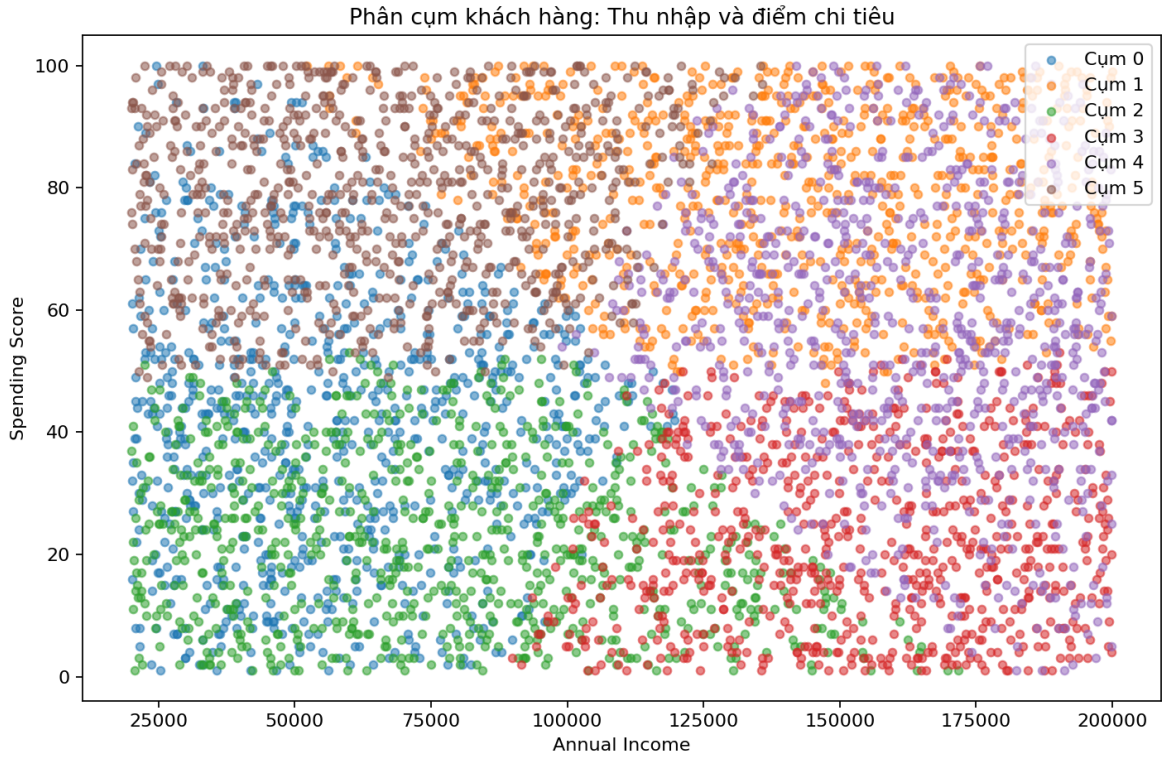
So sánh giá trị Spending Score trung bình giữa các cụm.

Clusters Age Spending



Biểu đồ phân bố khách hàng theo Age và Spending Score, được tô màu theo nhãn cụm.

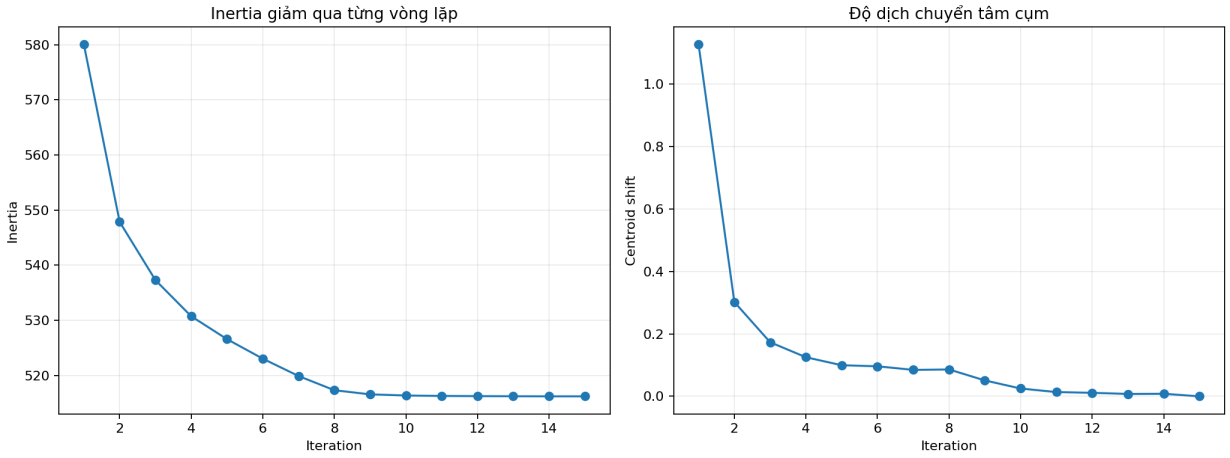
Clusters Income Spending



Biểu đồ phân bố khách hàng theo Annual Income và Spending Score, được tô màu theo nhãn cụm.

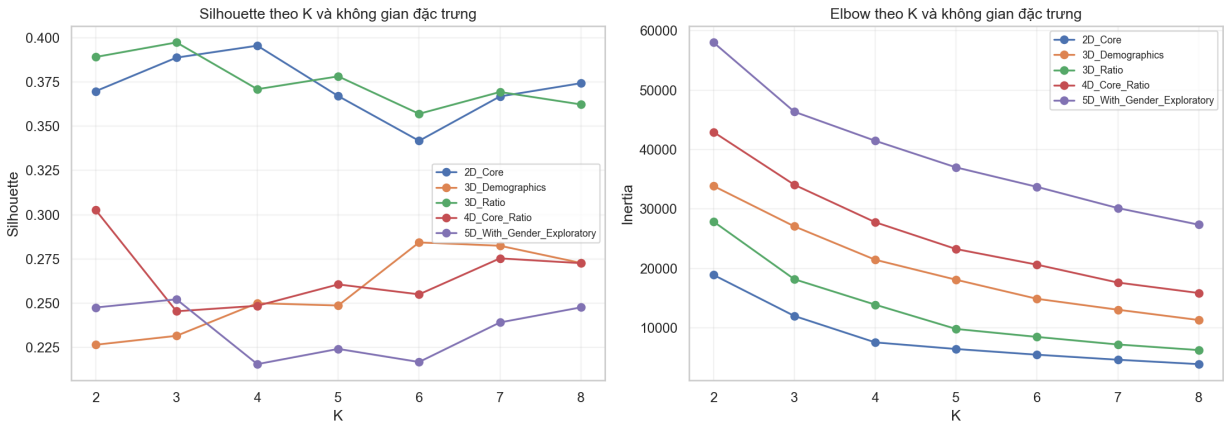
6.5. Thực nghiệm mở rộng

Kmeans Convergence



Minh họa quá trình tâm cụm thay đổi qua các vòng lặp của K-means.

Feature Space Comparison



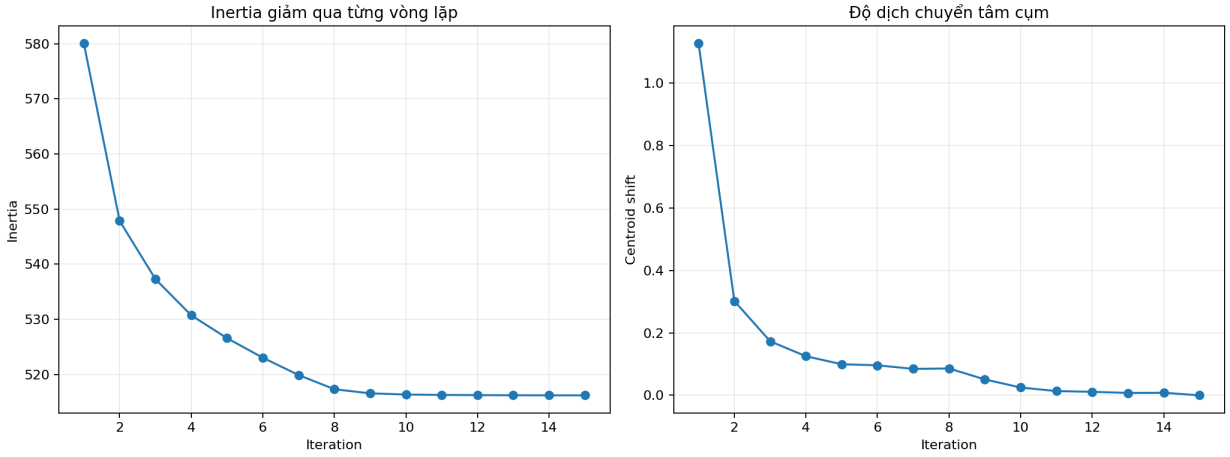
So sánh kết quả phân cụm trên các không gian đặc trưng khác nhau.

7. Thực nghiệm mở rộng

Lần chạy này có dữ liệu hoặc hình ảnh thuộc nhóm thực nghiệm mở rộng.

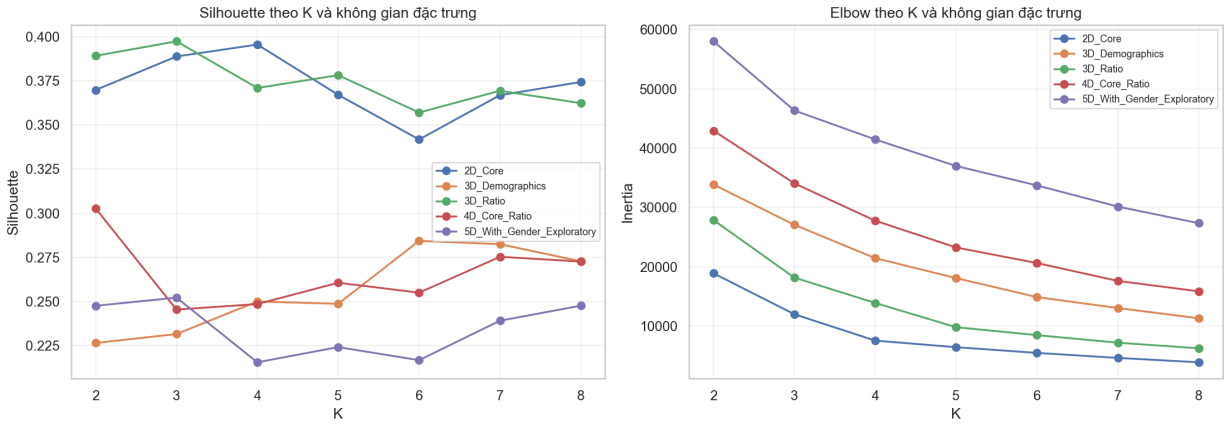
Các hình ảnh thực nghiệm mở rộng:

Kmeans Convergence



Minh họa quá trình tâm cụm thay đổi qua các vòng lặp của K-means.

Feature Space Comparison



So sánh kết quả phân cụm trên các không gian đặc trưng khác nhau.

8. Nhật ký thực thi

Nội dung log được lấy từ file:

logs\pipeline_20261111_012322_8b668d.log

```
[2026-11-11T01:23:22+07:00] [START] [PIPELINE] B■t ■■u pipeline Lab03.
[2026-11-11T01:23:22+07:00] [START] [EDA] B■t ■■u giai ■o■n EDA.
[2026-11-11T01:23:24+07:00] [SUCCESS] [EDA] Hoàn thành trong 1.7395 giây.
[2026-11-11T01:23:24+07:00] [START] [PREPROCESSING] B■t ■■u giai ■o■n PREPROCESSING.
[2026-11-11T01:23:24+07:00] [SUCCESS] [PREPROCESSING] Hoàn thành trong 0.6392 giây.
[2026-11-11T01:23:24+07:00] [START] [TRAINING] B■t ■■u giai ■o■n TRAINING.
[2026-11-11T01:23:25+07:00] [SUCCESS] [TRAINING] Hoàn thành trong 0.8839 giây.
[2026-11-11T01:23:25+07:00] [START] [EVALUATION] B■t ■■u giai ■o■n EVALUATION.
[2026-11-11T01:23:26+07:00] [SUCCESS] [EVALUATION] Hoàn thành trong 0.9543 giây.
[2026-11-11T01:23:26+07:00] [START] [VISUALIZATION] B■t ■■u giai ■o■n VISUALIZATION.
[2026-11-11T01:23:26+07:00] [SUCCESS] [VISUALIZATION] Hoàn thành trong 0.1932 giây.
[2026-11-11T01:23:26+07:00] [SUCCESS] [PIPELINE] Toàn b■ Pipeline ■ã hoàn thành thành công.
[2026-11-11T01:23:26+07:00] [SUCCESS] [PIPELINE] K■t thúc pipeline.
```

9. Các tệp đầu ra

Tệp	Vai trò
customers_clean.csv	Dữ liệu sau làm sạch
X_scaled.csv	Dữ liệu đã chuẩn hóa
scaler.json	Thông tin tham số chuẩn hóa
experiment_results.csv	Kết quả thử nghiệm các giá trị K
best_kmeans.pkl	Mô hình K-means đã huấn luyện
customer_clusters.csv	Dữ liệu khách hàng kèm nhãn cụm
cluster_profile.csv	Thống kê đặc trưng của từng cụm
progress_results/	Trạng thái Pipeline theo Run_ID
logs/	Nhật ký thực thi theo Run_ID
reports/figures/	Biểu đồ theo Run_ID và giai đoạn

10. Kết luận và nhận xét

• Giá trị K trong cấu hình tốt nhất: 6.0.

• Silhouette Score: 0.2859.

• Inertia: 14,905.6510.

• Số cụm được tạo trong kết quả: 6.

• Tổng số khách hàng được phân cụm: 15,079.

Ưu điểm:

• K-means có quy trình đơn giản, dễ triển khai và dễ giải thích.

• Chuẩn hóa dữ liệu giúp hạn chế ảnh hưởng của sự khác biệt thang đo giữa các đặc trưng.

• Có thể sử dụng hồ sơ cụm để phân tích hành vi và đặc điểm khách hàng.

Hạn chế:

• K-means cần xác định số cụm K trước khi huấn luyện.

• Kết quả có thể phụ thuộc vào cách khởi tạo tâm cụm.

• Silhouette Score và Inertia cần được xem xét kết hợp, không nên sử dụng riêng một chỉ số để kết luận.

• Silhouette Score thấp có thể phản ánh các cụm chưa tách biệt rõ ràng trong không gian đặc trưng đã chọn.

Kết luận chung: Kết quả phân cụm cần được đánh giá đồng thời qua chỉ số định lượng, kích thước cụm, hồ sơ đặc trưng và biểu đồ trực quan. Việc lựa chọn K cần cân bằng giữa độ gắn kết trong cụm, độ tách biệt giữa các cụm và khả năng diễn giải trong thực tế.

_Báo cáo được tạo tự động cho Run_ID: 20261111_012322_8b668d._